

HEART DISEASE PREDICTION

INDUZIONE DI REGOLE E ALBERI DECISIONALI CON PROLOG: GINI E ENTROPIA AL
VARIARE DELLA GRANULARITÀ

Studente: Federico Beni (S1123835)

Docente: Aldo Franco Dragoni

Corso: Intelligenza Artificiale A.A. 2025/2026

DATASET

- Il dataset in questione si chiama *UCI Heart Disease Data*;
- Presenta un totale di **920 record** e di **14 attributi**.
 - L'obiettivo è determinare se un paziente è malato o meno osservando le diagnosi relative ai sintomi, di fatto la **variabile target** è **Num**, convertita a valore binario per una classificazione, appunto, binaria ($0=\text{no}$; $1,2,3,4=\text{yes}$).
 - Nella fase di **preprocessing**, tutti i valori mancanti ed i valori pari a 0 anomali sono stati sostituiti con '**unknown**'.

Per i successivi test effettuati, il dataset è stato suddiviso come segue:

- Training set: 644 record
- Test set: 276 record.

Attributo	Valore
Age	Valori compresi tra 28 e 77
Sex	male, female
Cp	typical angina, atypical angina, non-anginal, asymptomatic
trestbps	Valori da 80 a 200
chol	Valori da 85 a 603
Fbs	true, false
Restecg	normal, stt abnormality, lv ipetrophy
Thalach	Valori da 60 a 202
Exang	true, false
Oldpeak	Valori da -26 a 62
Slope	upsloping, flat, downsloping
Ca	0, 1, 2, 3
Thal	normal, fixed defect, reversible defect
Num	0, 1, 2, 3, 4

SCRIPT UTILIZZATI

- `discretizza1/2/3.pl` e `discretizza4.py`
- `crea_heart_dataset.pl`
- `heart_RulesInduction.pl`
- `heart_Gini_TreeInduction.pl`
- `heart_Entropia_TreeInduction.pl`

BASELINE: APPROCCIO SENZA DISCRETIZZAZIONE

```
49 ==> ???
50 ==> ???
51 ==> ???
52 ==> ???
53 ==> ???
54 ==> ???
55 ==> ???
56 ==> ???
57 ==> yes
58 ==> ???
59 ==> ???
60 ==> ???
61 ==> ???
62 ==> ???
63 ==> ???
64 ==> ???
65 ==> ???
66 ==> ???
67 ==> ???
68 ==> ???
69 ==> ???
70 ==> ???
71 ==> ???
72 ==> ???
73 ==> ???
74 ==> ???
75 ==> ???
76 ==> ???
77 ==> ???
149 ==> yes
150 ==> yes
151 ==> ???
152 ==> ???
153 ==> ???
154
    age
        28 ==> ???
        29 ==> ???
```

Albero generato con Gini.

```
192 ==> ???
200 ==> ???
unknown ==> ???
1 ==> ???
2 ==> yes
3 ==> ???
4 ==> ???
5 ==> ???
6 ==> ???
7 ==> ???
8 ==> ???
9 ==> ???
11 ==> ???
12 ==> ???
13 ==> ???
14 ==> ???
15 ==> ???
16 ==> ???
17 ==> ???
18 ==> ???
19 ==> ???
21 ==> ???
22 ==> ???
23 ==> ???
24 ==> ???
25 ==> ???
26 ==> ???
28 ==> ???
29 ==> ???
31 ==> ???
32 ==> ???
34 ==> ???
35 ==> ???
36 ==> ???
37 ==> ???
38 ==> ???
42 ==> ???
44 ==> ???
56 ==> ???
62 ==> ???
unknown ==> ???
upsloping ==> yes
atypical angina ==> yes
```

Albero generato con Entropia.

```
Albero = t(chol, [85:1(no), 100:t(age, [28:null, 29:null, 30:null, ..., ..., ...|...]), 117:1(yes), 126:1(no), 129:1(no), 131:null, 132:1(...)|..., ..., ...|...]) .
```

Albero generato con Gini (struttura compatta).

```
Albero = t(fbs, [false:t(sex, [female:t(exang, [false:t(..., ...), ...|...]), male:t(exang, [...|...|...])]), true:t(sex, [female:t(exang, [...|...|...]), male:t(exang, [...|...])])]) .
```

Albero generato con Entropia (struttura compatta).

```
?- stampa_matrice_di_confusione.
Test effettuati :272
Test non classificati :147
Veri Negativi 29   Falsi Positivi 19
Falsi Negativi 28   Veri Positivi 49
Accuratezza: 0.624
Errore: 0.376
true .
```

Matrice di confusione generata con Gini.

```
?- stampa_matrice_di_confusione.
Test effettuati :272
Test non classificati :83
Veri Negativi 72   Falsi Positivi 18
Falsi Negativi 17   Veri Positivi 82
Accuratezza: 0.8148148148148
Errore: 0.18518518518518523
true .
```

Matrice di confusione generata con Entropia.

- L'albero ad Entropia riduce drasticamente i casi non classificati (83) rispetto a Gini (147), dimostrando una miglior capacità di **copertura** del Test Set nella Baseline.
- Già dalla baseline l'Entropia raggiunge una buona accuratezza a differenza di Gini

BASELINE: APPROCCIO SENZA DISCRETIZZAZIONE


```
?- apprendi(yes).  
  
yes<=  
[oldpeak=25]  
[trestbps=95]  
[trestbps=144]  
[chol=282]  
[thalach=108]  
[trestbps=115, sex=male]  
[trestbps=136]  
[trestbps=200]  
[thalach=119]  
[oldpeak=28]  
[thalach=105, ca=unknown]  
[thalach=102]  
[thalach=103]  
[thalach=117]  
[thalach=123]
```

```
?- apprendi(no).  
  
no<=  
[thalach=172]  
[cp='atypical angina',slope=unknown,exang=false]  
[chol=240]  
[chol=220]  
[chol=308]  
[thalach=178]  
[thalach=179]  
[chol=182]  
[chol=250]  
[chol=271]  
[age=45,sex=female]  
[trestbps=104]
```

```
?- stampa_matrice_di_confusione.  
Test effettuati :272  
Test non classificati :94  
Veri Negativi 58 Falsi Positivi 21  
Falsi Negativi 17 Veri Positivi 82  
Accuratezza: 0.7865168539325843  
Errore: 0.2134831460674157  
true.
```

DISCRETIZZAZIONE: PIPELINE DI LAVORO

La pipeline di lavoro eseguita per ogni discretizzazione è la seguente:



DISCRETIZZAZIONE1

paziente(63,male,'typical angina',145,233,true,'lv hypertrophy',150,false,23,downsloping,0,'fixed defect',0).

discretizza1.pl

pd(old,male,'typical angina',high,high,true,'lv hypertrophy',high,false,depression,downsloping,0,'fixed defect',no.)

crea_heart_dataset.pl

pd(no,[age=old, sex=male, cp='typical angina', trestbps=high, chol=high, fbs=true, restecg='lv hypertrophy', thalach=high, exang=false, oldpeak=depression, slope=downsloping, ca=0, thal='fixed defect']).

DISCRETIZZAZIONE1

discretizza1.pl

```
:- ensure_loaded('heart_database.pl').  
  
start :-  
    tell('heart_databaseDiscl.pl'), % Apre il file di output  
    elabora_fatti, % Avvia il ciclo di elaborazione  
    told. % Chiude il file  
  
elabora_fatti :-  
    % Legge un fatto dal database grezzo  
    paziente(Age, Sex, Cp, Trestbps, Chol, Fbs, Restecg, Thalach, Exang, Oldpeak, Slope, Ca, Thal, Num),  
    %DISCRETIZZAZIONE DEGLI ATTRIBUTI  
    % 1. Età : young (<35), adult (35-60), old (>60)  
    discretizza_eta(Age, AgeGroup),  
    % 2. Pressione: optimal (<120), normal (120-139), high (>=140)  
    discretizza_bp(Trestbps, BP_Level),  
    % 3. Colesterolo: normal (<200), high (200-239), very_high (>=240)  
    discretizza_chol(Chol, Chol_Level),  
    % 4. Battito Cardiaco: low (<150), high (>=150)  
    discretizza_talach(Thalach, Talach_Level),  
    % 5. Depressione ST (Oldpeak): no_depression (0), depression (>0)  
    discretizza_oldpeak(Oldpeak, Depression),  
    % 6. Target (Num): 0 -> no (Sano), >0 -> yes (Malato)  
    discretizza_target(Num, Target),  
  
    % Gli attributi categorici (Sex, Cp, Fbs, Restecg, Exang, Slope, Ca, Thal)  
    % vengono passati direttamente o gestiti solo per 'unknown'.
```

```
% SCRITTURA DEL FATTO ELABORATO  
write('pd('),  
    writeq(AgeGroup), write(','),  
    writeq(Sex), write(','),  
    writeq(Cp), write(','),  
    writeq(BP_Level), write(','),  
    writeq(Chol_Level), write(','),  
    writeq(Fbs), write(','),  
    writeq(Restecg), write(','),  
    writeq(Talach_Level), write(','),  
    writeq(Exang), write(','),  
    writeq(Depression), write(','),  
    writeq(Slope), write(','),  
    writeq(Ca), write(','),  
    writeq(Thal), write(','),  
    writeq(Target), writeln(')').  
  
fail. % Forza il backtracking per trovare il prossimo paziente  
elabora_fatti. % Termina quando non ci sono più fatti  
  
% REGOLE DI DISCRETIZZAZIONE (inclusa gestione 'unknown')  
  
% ETA  
discretizza_eta('unknown', 'unknown') :- !.  
discretizza_eta(A, 'young') :- A < 35, !.  
discretizza_eta(A, 'adult') :- A =< 60, !.  
discretizza_eta(_, 'old').  
  
% PRESSIONE (Trestbps)  
discretizza_bp('unknown', 'unknown') :- !.  
discretizza_bp(P, 'optimal') :- P < 120, !.  
discretizza_bp(P, 'normal') :- P =< 139, !.  
discretizza_bp(_, 'high').  
  
% COLESTEROLO (Chol)  
discretizza_chol('unknown', 'unknown') :- !.  
discretizza_chol(C, 'normal') :- C < 200, !.  
discretizza_chol(C, 'high') :- C =< 239, !.  
discretizza_chol(_, 'very_high').
```

DISCRETIZZAZIONE1

crea_heart_dataset.pl

```
:- ensure_loaded('heart_databaseDisc1.pl').  
  
start :-  
    tell('heart_datasetDisc1.pl'),  
  
    %GENERAZIONE DOMINI (METADATI)  
  
    % Per ogni attributo, uso setof per trovare tutti i valori unici presenti nel DB.  
    % La sintassi A^B^... serve a dire "ignorando le altre variabili".  
  
    % 1. Age (Eta)  
    setof(Age, Sex^Cp^Bp^Chol^Fbs^Ecg^Hr^Ex^Dep^Slp^Ca^Thal^Tar^pd(Age, Sex, Cp, Bp, Chol, Fbs, Ecg, Hr, Ex, Dep, Slp, Ca, Thal, Tar), DomAge),  
    write('a(age,'), writeq(DomAge), writeln('.')).  
  
    % 2. Sex  
    setof(Sex, Age^Cp^Bp^Chol^Fbs^Ecg^Hr^Ex^Dep^Slp^Ca^Thal^Tar^pd(Age, Sex, Cp, Bp, Chol, Fbs, Ecg, Hr, Ex, Dep, Slp, Ca, Thal, Tar), DomSex),  
    write('a(sex,'), writeq(DomSex), writeln('.')).  
  
    % 3. Cp (Chest Pain)  
    setof(Cp, Age^Sex^Bp^Chol^Fbs^Ecg^Hr^Ex^Dep^Slp^Ca^Thal^Tar^pd(Age, Sex, Cp, Bp, Chol, Fbs, Ecg, Hr, Ex, Dep, Slp, Ca, Thal, Tar), DomCp),  
    write('a(cp,'), writeq(DomCp), writeln('.')).  
  
    % 4. Trestbps (Pressione)  
    setof(Bp, Age^Sex^Cp^Chol^Fbs^Ecg^Hr^Ex^Dep^Slp^Ca^Thal^Tar^pd(Age, Sex, Cp, Bp, Chol, Fbs, Ecg, Hr, Ex, Dep, Slp, Ca, Thal, Tar), DomBp),  
    write('a(trestbps,'), writeq(DomBp), writeln('.')).
```

DISCRETIZZAZIONE1

crea_heart_dataset.pl

```
scrivi_esempi :-  
    % CASO POSITIVO (MALATO - 'yes')  
    pd(Age, Sex, Cp, Bp, Chol, Fbs, Ecg, Hr, Ex, Dep, Slp, Ca, Thal, 'yes'),  
    write('e(yes,[')).  
    ▲  
    write('age='), writeq(Age), write(',', ','),  
    write('sex='), writeq(Sex), write(',', ','),  
    write('cp='), writeq(Cp), write(',', ','),  
    write('trestbps='), writeq(Bp), write(',', ','),  
    write('chol='), writeq(Chol), write(',', ','),  
    write('fbs='), writeq(Fbs), write(',', ','),  
    write('restecg='), writeq(Ecg), write(',', ','),  
    write('thalach='), writeq(Hr), write(',', ','),  
    write('exang='), writeq(Ex), write(',', ','),  
    write('oldpeak='), writeq(Dep), write(',', ','),  
    write('slope='), writeq(Slp), write(',', ','),  
    write('ca='), writeq(Ca), write(',', ','),  
    write('thal='), writeq(Thal), writeln(']).').',  
    fail.  
  
scrivi_esempi :-  
    % CASO NEGATIVO (SANO - 'no')  
    pd(Age, Sex, Cp, Bp, Chol, Fbs, Ecg, Hr, Ex, Dep, Slp, Ca, Thal, 'no'),  
    write('e(no,[')).  
    write('age='), writeq(Age), write(',', ','),  
    write('sex='), writeq(Sex), write(',', ','),  
    write('cp='), writeq(Cp), write(',', ','),  
    write('trestbps='), writeq(Bp), write(',', ','),  
    write('chol='), writeq(Chol), write(',', ','),  
    write('fbs='), writeq(Fbs), write(',', ','),  
    write('restecg='), writeq(Ecg), write(',', ','),  
    write('thalach='), writeq(Hr), write(',', ','),  
    write('exang='), writeq(Ex), write(',', ','),  
    write('oldpeak='), writeq(Dep), write(',', ','),  
    write('slope='), writeq(Slp), write(',', ','),  
    write('ca='), writeq(Ca), write(',', ','),  
    write('thal='), writeq(Thal), writeln(']).').',  
    fail.  
  
scrivi_esempi :- told.
```

DISCRETIZZAZIONE1

La prima discretizzazione prevede la suddivisione nelle seguenti fasce di valori:

- **Età (Age)**: 3 fasce – *Young* (<35), *Adult* (35-60), *Old* (>60).
- **Pressione (Trestbps)**: 3 livelli – *Optimal* (<120), *Normal* (120-139), *High* (≥ 140).
- **Colesterolo (Chol)**: 3 categorie – *Normal* (<200), *High* (200-239), *Very High* (≥ 240).
- **Frequenza Cardiaca (Thalach)**: Binarizzazione – *Low* (<150), *High* (≥ 150).
- **Depressione ST (Oldpeak)**: Binarizzazione – *No Depression* (0), *Depression* (>0).
- **Target (Num)**: Classificazione binaria – *No* (0), *Yes* (>0).

DISCRETIZZAZIONE1

```
ca
0 ==> yes
1 ==> yes
2 ==> ???
3 ==> yes
unknown
    thal
        fixed defect ==> ???
        normal ==> ???
        reversible defect ==> yes
        unknown
            cp
                asymptomatic ==> yes
                atypical angina ==> yes
                non-anginal ==> no
                typical angina ==> ???
            unknown ==> ???
        no_depression
            cp
                asymptomatic
                    ca
                        0 ==> ???
                        1 ==> ???
                        2 ==> yes
                        3 ==> ???
                    unknown
                        thalach
                            high ==> ???
                            low
                                chol
                                    high ==> yes
                                    . . .
```

```
?- apprendi(yes).
false.
```

```
?- apprendi(no).
false.
```

```
?- stampa_matrice_di_confusione.
false.
```

```
normal
slope
    downslloping ==> ???
    flat ==> ???
    unknown ==> ???
    upsloping ==> [no,yes]
st-t abnormality ==> ???
unknown ==> ???
true ==> ???
    true ==> ???
        old ==> ???
        young ==> ???
        1 ==> ???
        2 ==> ???
        3 ==> ???
        unknown ==> no
    unknown ==> ???
reversible defect
chol
    high
        oldpeak
            depression ==> yes
            no_depression ==> no
            unknown ==> ???
        normal ==> no
        unknown ==> ???
        very_high ==> no
    unknown
slope
    downslloping ==> ???
    flat
```

(sinistra Gini, destra Entropia)

- Presenza di **foglie impure** [no, yes]: l'ambiguità dei dati impedisce una classificazione univoca, causando il fallimento logico nel calcolo delle matrici e dell'apprendimento delle regole

DISCRETIZZAZIONE2

- **Età (Age):** 5 fasce – *Young* (<35), *Early Adult* (35-48), *Late Adult* (49-60), *Senior* (61-72), *Elderly* (>72).
- **Pressione (Trestbps):** 5 livelli – *Optimal* (<120), *Normal* (120-129), *High Normal* (130-139), *Grade 1 Hyp* (140-159), *Grade 2 Hyp* (≥ 160).
- **Colesterolo (Chol):** 5 categorie – *Desirable* (<180), *Borderline* (180-219), *High* (220-259), *Very High* (260-299), *Extreme* (≥ 300).
- **Frequenza Cardiaca (Thalach):** 4 livelli – *Very Low* (<90), *Low* (90-129), *Moderate* (130-169), *High* (≥ 170).
- **Depressione ST (Oldpeak):** 3 fasce – *None* (0), *Mild* (0.1-2.0), *Severe* (>2.0).

I risultati ottenuti dal secondo tentativo risultano identici al primo, senza alcun tipo di miglioramento; l'incremento di così poche fasce di valori mantiene i dati ancora troppo generici e la granularità ancora troppo bassa per gli algoritmi.

DISCRETIZZAZIONE3

- **Età (Age):** 10 fasce da 5 anni ciascuna (es. $age1 = 25-29, \dots, age10 = \geq 70$).
- **Pressione (Trestbps):** 10 fasce da 12 mmHg (es. $bp1 = 80-91, \dots, bp10 = \geq 188$).
- **Colesterolo (Chol):** 10 fasce da 50 mg/dl (es. $ch1 = 85-134, \dots, ch10 = \geq 535$).
- **Frequenza Cardiaca (Thalach):** 10 fasce da 15 bpm (es. $thalach1 = 60-74, \dots, thalach10 = \geq 195$).
- **Depressione ST (Oldpeak):** 10 fasce da 10 unità (da -30 a +60).

DISCRETIZZAZIONE3

```
op10 ==> ???
op2 ==> ???
op3 ==> no
op4 ==> ???
op5 ==> no
op6 ==> yes
op7 ==> ???
op8 ==> ???
op9 ==> ???
unknown ==> ???

typical angina
chol
  ch1 ==> ???
  ch10 ==> ???
ch2 ==> no
ch3
  trestbps
    bp1 ==> ???
    bp10 ==> ???
    bp2 ==> no
    bp3 ==> no
    bp4 ==> no
    bp5 ==> yes
    bp6 ==> no
    bp7 ==> no
    bp8 ==> no
    bp9 ==> ???
    unknown ==> yes
ch4
  thal
    fixed defect ==> no
    normal ==> no
    reversible defect ==> yes
```

Albero generato con Gini.

```
ch7 ==> ???
ch8 ==> ???
ch9 ==> ???
unknown ==> yes
age2 ==> ???
age3 ==> ???
age4 ==> ???
age5 ==> ???
age6 ==> ???
age7 ==> yes
age8 ==> ???
age9 ==> ???

st-t abnormality ==> ???
unknown ==> ???

slope
  downsloping ==> yes
  flat ==> yes
  unknown ==> no
  upsloping ==> ???

op5 ==> yes
op6 ==> ???
op7 ==> yes
op8 ==> ???
op9 ==> ???
unknown ==> ???

atypical angina ==> yes
non-anginal
  chol
    ch1 ==> ???
    ch10 ==> ???
    ch2 ==> ???
    ch3 ==> no
    ch4
      oldpeak
        op1 ==> ???
        op10 ==> ???
        op2 ==> ???
        op3 ==> ???
```

Albero generato con Entropia.

```
Albero = t(cp, [asymptomatic:t(ca, [0:t(thal, ['fixed defect':t(..., ...), ... : ... | ...]), 1:t(yes), 2:t(thal, ... | ...), 3:t(..., ...), ... : ...]), 'atypical angina':t(slope, [downsloping:1(no), flat:t(chol, [...] | ...], unknown:t(..., ...), ... : ...]), 'non-anginal':t(age, [age1:null, age10:t(..., ...), ... : ... | ...]), 'typical angina':t(chol, [ch1:null, ... | ... | ...]))].
```

Albero generato con Gini (struttura compatta)

```
Albero = t(fbs, [false:t(sex, [female:t(exang, [false:t(..., ...), ... : ...]), male:t(exang, [...] | ...)], true:t(sex, [female:t(oldpeak, [...] | ...), male:t(exang, [...] | ...)]))].
```

Albero generato con Entropia
(struttura compatta).

DISCRETIZZAZIONE3

```
?- stampa_matrice_di_confusione.  
Test effettuati :276  
Test non classificati :32  
Veri Negativi 88 Falsi Positivi 35  
Falsi Negativi 21 Veri Positivi 100  
Accuratezza: 0.7704918032786885  
Errore: 0.2295081967213115
```

Matrice di confusione generata con Gini.

```
?- stampa_matrice_di_confusione.  
Test effettuati :276  
Test non classificati :76  
Veri Negativi 79 Falsi Positivi 25  
Falsi Negativi 22 Veri Positivi 74  
Accuratezza: 0.765  
Errore: 0.235
```

Matrice di confusione generata con Entropia.

```
?- apprendi(yes).  
false.  
  
?- apprendi(no).  
false.
```

- Netto miglioramenti per l'albero con Gini, sia per i non classificati che per l'accuratezza.
- L'Entropia riesce a diminuire i casi non classificati ma ottiene un'accuratezza minore rispetto alla baseline.
- Tuttavia il comando *apprendi* continua a fallire probabilmente per la presenza di ambiguità residue che impediscono una separazione netta tra le classi.

DISCRETIZZA4

discretizza4.py

```
import re

# Funzione di discretizzazione base
def discretizza(valore, v_min, v_max, num_fasce=50):
    if valore == 'unknown': return 'unknown'
    try:
        valore = float(valore)
        ampiezza = (v_max - v_min) / num_fasce
        if valore <= v_min: return 1
        if valore >= v_max: return num_fasce
        return int((valore - v_min) // ampiezza) + 1
    except:
        return 'unknown'

# Helper per gestire prefissi e unknown
def get_val(prefisso, val_raw, range_key):
    res = discretizza(val_raw, *ranges[range_key])      # Chiama discretizzazione
    return 'unknown' if res == 'unknown' else f"{prefisso}{res}" # gestione nknown

# Configurazione range (Min, Max)
ranges = {
    'age': (28, 77), 'trestbps': (80, 200),
    'chol': (85, 603), 'talach': (60, 202),
    'oldpeak': (-26, 62)
}

input_file = 'heart_database.pl'
output_file = 'heart_databaseDisc4.pl'
```

```
with open(input_file, 'r') as f, open(output_file, 'w') as out:
    for riga in f:
        if not riga.startswith('paziente'): continue      # Filtra i fatti

        contenuto = re.search(r'\((.*))', riga).group(1)
        v = [x.strip().strip('"') for x in contenuto.split(',')]

        # 1. Discretizzazione con controllo Unknown
        age_d = get_val("age", v[0], 'age')                # Fascia Age
        bp_d = get_val("bp", v[3], 'trestbps')             # Fascia Pressione
        ch_d = get_val("ch", v[4], 'chol')                 # Fascia Colesterolo
        hr_d = get_val("talach", v[7], 'talach')           # Fascia Freq. Cardiaca
        op_d = get_val("op", v[9], 'oldpeak')              # Fascia Oldpeak

        # 2. Conversione Target (0 -> no, 1-4 -> yes)
        target_final = 'no' if v[13].strip('.') == '0' else 'yes'

        # 3. Scrittura riga pd/14
        nuova_riga = (f"pd({age_d},{v[1]},{v[2]},{bp_d},{ch_d},{v[5]},"
                      f'{v[6]},{hr_d},{v[8]},{op_d},{v[10]},{v[11]},'
                      f'{v[12]},{target_final}).\n")
        out.write(nuova_riga)                                # Scrive su file

    print(f"File {output_file} generato.")
```

DISCRETIZZAZIONE4

```
?- apprendi(yes).  
  
yes<==  
[thalach=talach12]  
[ca=3,cp=asymptomatic]  
[thalach=talach19,slope=flat]  
[trestbps=bp7]  
[thalach=talach16,ca=unknown]  
[oldpeak=op29,fbs=false]  
[oldpeak=op31]  
[trestbps=bp24]  
[thalach=talach14,restecg=normal]  
[trestbps=bp27]  
[oldpeak=op36]  
[thalach=talach17,exang=true]  
[thalach=talach23,oldpeak=op16]  
[ca=2,slope=flat]  
[age=age45]  
[trestbps=bp33]  
[trestbps=bp50]  
[thalach=talach5]  
[oldpeak=op27]  
[oldpeak=op33]
```

```
?- stampa_matrice_di_confusione.  
Test effettuati :276  
Test non classificati :70  
Veri Negativi 80 Falsi Positivi 16  
Falsi Negativi 15 Veri Positivi 95  
Accuratezza: 0.8495145631067961  
Errore: 0.15048543689320393
```

```
?- apprendi(no).  
  
no<==  
[age=age10]  
[thalach=talach45]  
[age=age15,exang=false]  
[age=age18,exang=false]  
[cp='atypical angina',chol=ch12]  
[thalach=talach42,restecg=normal]  
[cp='atypical angina',slope=unknown,sex=female]  
[thalach=talach40,restecg=normal]  
[thalach=talach44]  
[ca=0,trestbps=bp21]  
[cp='atypical angina',age=age28]  
[age=age8,exang=false,sex=female]  
[thalach=talach33,cp='non-anginal']  
[cp='atypical angina',slope=unknown,restecg=normal,trestbps=bp17]  
[ca=0,thalach=talach37]  
[age=age12,thal=unknown]  
[age=age3]  
[trestbps=bp1]  
[trestbps=bp12,exang=false]  
[trestbps=bp8]  
[chol=ch1]
```

- Con 50 fasce di valori l'algoritmo riesce ad apprendere.
- Dalla matrice di confusione generata dall'induzione di regole, si nota, rispetto alla baseline, un incremento dell'accuratezza (dal 78% all'85%) e una diminuzione dei casi non classificati (da 94 a 70).

DISCRETIZZAZIONE4

```

age40 ==> ???
age41 ==> ???
age42 ==> ???
age43 ==> ???
age44 ==> yes
age45 ==> ???
age46 ==> ???
age47 ==> no
age48 ==> ???
age49 ==> ???
age5 ==> ???
age50 ==> ???
age6 ==> ???
age7 ==> ???
age8 ==> no
age9 ==> ???
typical angina
age
  age1 ==> ???
  age10 ==> ???
  age11 ==> ???
  age12 ==> ???
  age13 ==> no
  age14 ==> ???
  age15 ==> ???
  age16
    chol
      ch1 ==> ???
      ch10 ==> ???
      ch11 ==> ???
      ch12 ==> ???
      ch13 ==> ???
      ch14 ==> no
      ch15 ==> ???
      ch16 ==> ???
      ch17 ==> ???

```

Albero generato con Gini.

```

op35 ==> ???
op36 ==> ???
op37 ==> ???
op39 ==> ???
op40 ==> ???
op47 ==> ???
op50 ==> ???
op7 ==> ???
op9 ==> ???
unknown ==> ???
slope
  downsloping ==> yes
  flat ==> yes
  unknown
    oldpeak
      op1 ==> ???
      op10 ==> ???
      op11 ==> ???
      op12 ==> ???
      op14 ==> ???
      op15
        age
          age1 ==> ???
          age10 ==> ???
          age11 ==> ???
          age12 ==> ???
          age13 ==> ???
          age14 ==> ???
          age15 ==> ???
          age16 ==> ???
          age17 ==> ???
          age18 ==> ???
          age19 ==> ???
          age2 ==> ???
          age20 ==> no
          age21 ==> ???
          age22 ==> ???
          age23 ==> ???
          age24 ==> ???

```

Albero generato con Entropia.

```

Albero = t(cp, [asymptomatic:t(age, [age1:null, age10:1(no), age11:1( yes), age12:t(..., ...), ... : ...|...)], 'atypical angina':t(age, [age1:1(no), age10:1(no), age11:1(...), ... : ...|...]), 'non-anginal':t(thalach, [talach1:null, talach10:1(...), ... : ...|...]), 'typical angina':t(age, [age1:null, ... : ...|...])])

```

Albero generato con Gini (forma compatta).

```

Albero = t(fbs, "[false:t(sex, [female:t(exang, [false:t(..., ...), ... : ...]), male:t(exang, [... : ...|...])]), true:t(sex, [female:t(exang, [... : ...|...]), male:t(exang, [...|...])])]")

```

Albero generato con Entropia (forma compatta).

```

?- stampa_matrice_di_confusione.
Test effettuati :276
Test non classificati :111
Veri Negativi 61 Falsi Positivi 16
Falsi Negativi 18 Veri Positivi 70
Accuratezza: 0.793939393939394
Errore: 0.20606060606060606

```

Matrice di confusione generata con Gini.

```

?- stampa_matrice_di_confusione.
Test effettuati :276
Test non classificati :99
Veri Negativi 72 Falsi Positivi 23
Falsi Negativi 10 Veri Positivi 72
Accuratezza: 0.8135593220338984
Errore: 0.18644067796610164

```

Matrice di confusione generata con Entropia.

Dalle matrici di confusione si nota:

- **Gini:** non classificati diminuiti rispetto alla baseline, ma aumentati rispetto a Disc3; accuratezza aumentata in generale.
- **Entropia:** non classificati aumentati, sia rispetto alla baseline che alla Disc3, ma risalita del valore dell'accuratezza, che è praticamente la stessa della baseline.

CONCLUSIONI E CONFRONTO FINALE

Impatto della Granularità

- **Bassa (Disc1/2): Underfitting.** Ambiguità e foglie impure [no, yes] bloccano l'apprendimento.
- **Media (Disc3): Massima Generalizzazione.** Punto di equilibrio con il minor numero di casi non classificati (NC).
- **Alta (Disc4): Massima Precisione.** L'accuratezza risale all'81%, ma aumenta la frammentazione (NC) rispetto a Disc3.

Gini vs Entropia:

- **Entropia:** Più robusta sui dati con granularità elevata (Baseline e Disc4, 84 e 99 NC). Tende a massimizzare l'accuratezza.
- **Gini:** Estremamente dipendente dal preprocessing; migliora nettamente e supera l'Entropia nei casi in cui i dati sono meno frammentati.

GRAZIE PER L'ATTENZIONE!



[Codice sorgente su GitHub](#)